

神经网络分析时间序列：心跳间隔序列预测



王尧 2 个月前


为什么研究心跳间隔序列

在算法自动识别心电图(ECG)这个领域，要解决形态识别和周期性识别两方面问题。形态识别就是从ECG信号的高低起伏中识别出PQRST特征点。但形态识别不能解决所有问题：当原始信号信噪比不高，混杂了部分难以通过滤波等手段抑制的噪音时，单纯形态无法给出确定性判断。这种时候就需要根据此前的若干个心跳间隔推算出之后若干个心跳可能出现在什么位置（即周期性规律），在可能出现的时间区间内搜索形态上最可能的PQRST特征点。


什么是心跳间隔序列

心跳间隔序列，指的是用心脏相邻两次跳动的时间间隔组成的时间序列。其中心脏一次跳动到下一次跳动之间的时间也称为心动周期或心跳间隔。由于受到复杂的人体生物机制调节（包括但不限于交感神经、副交感神经等），每个心跳间隔的长度并不一样。

如果我们将每个心跳间隔用线连起来，那么将是下图所示的样子，数据来自MIT-BIH Arrhythmia 数据库[1]中编号为100的测试记录。图中纵坐标单位为ms，代表这次心跳周期的时间长度，横坐标是每一次心跳的序号。这是一个健康人测量到的心率变化，可以看出其心动周期长度既呈现快速的起落，也呈现相对中长期的趋势，同时还存在个别异常点。



接下来一张图是[1]中编号为200的一份心律不齐情况下的心跳间隔序列，对比前一幅图片，可以看到在心律不齐发生的情况下，被试者心跳间隔变化幅度明显变大，在500-1000+ms之间反复变化。



问题定义和模型设计

根据前述背景，此问题可以抽象为：给定前 N 个心跳间隔，预测第 $N+1$ 个心跳间隔最可能是多少。

抽象之后的问题是一个典型的时间序列预测问题。在常用的神经网络结构中，RNN是比较适合表征时间序列特征的结构，因此我选择了LSTM作为模型的主要部分。对于输入层，考虑到时间序列的关键规律在于变化趋势，为了凸显这个趋势，可以使用batch normalization将数据归一化，提升学习效率。网络的最终输出是下一个心跳的具体值，那么使用线性回归的全连接层处理LSTM的输出就比较合适。综合上述考虑，设计出的模型基本结构如下图所示。



Loss函数的选择

如何评价预测出的下一个心跳间隔准不准？这里有两种选择。


一种是追求绝对值的准确，即预测值与真实值误差越小越好，这种情况下RMSE[2]是一个比较合适的误差评价指标。

另一种是评价预测值与真实值误差是否落在一定范围内。由于前N个心跳间隔不一定包含决定第N+1个点心跳间隔的所有信息，要求严格精确的预测第N+1个点并不合理，具体到目标应用中也没必要精确预测第N+1个点，只要给出第N+1个心跳最可能出现的时间区间就可以了。这种思路下网络结构和损失函数都要做相应调整。


出于简单和直观的考虑，本文采取上述第一种设计思路，即使用RMSE评价Loss. RMSE是由预测向量与标签向量做初等运算得到的，所以具备可导的数学特性，可以使用梯度下降法调优。

性能评价

从MIT-BIH数据库找到一份正常心率的记录，取其中90%做训练，10%做测试，下图是测试集预测效果图，橙色为真实值，蓝色为预测值，纵坐标单位为ms。从图中可以看到，除了真实曲线的几次较大突变，预测曲线基本学习到了真实曲线的波动规律。

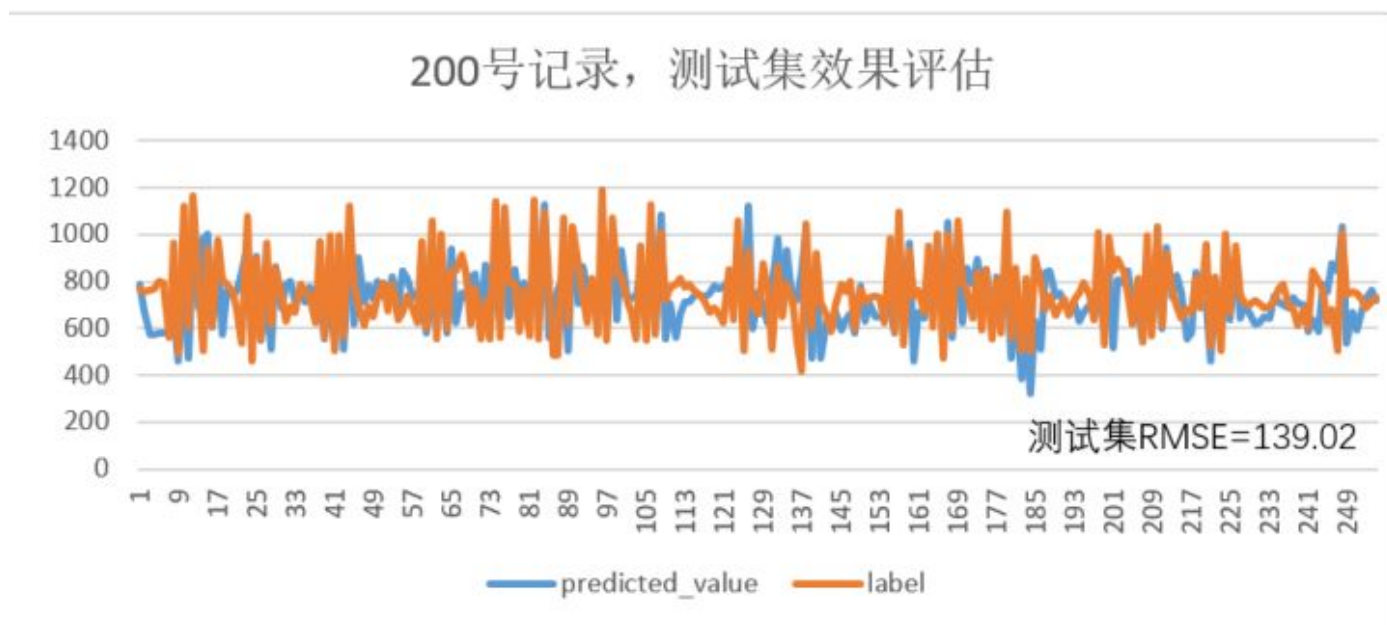


上述结果验证了对于一个人一次测量，网络基于前90%的心跳间隔训练可以较为良好的预测最后10%的心跳间隔，那么如果是两个不同人，取一个人的数据训练，在另一个人身上是否有效呢？下图回答了这个问题，训练数据取自100号记录，测试数据取自101号记录。虽然RMSE较之上一张图有增加，但是预测曲线仍然能较好的跟踪真实曲线的变化趋势。



前面展示两份数据都是正常心律测量记录，在心律不齐发生时，被试者短时间内心率会发生较大变化，这种情况下网络学习情况如何？

从MIT-BIH数据库中找到一份编号为200的心律不齐用户的测试结果。利用这份数据，选择前90%的数据训练，最后10%的数据测试，得到测试集上跟踪曲线如下。相比于健康心律，心律不齐的情况下预测难度提升，RMSE显著增大，即预测误差增大。但从曲线跟踪趋势来看，预测值仍然可以比较好的跟踪真实曲线的波动趋势，实现趋势判断。



总结与讨论

本文使用一个较为简单的神经网络结构，在MIT-BIH公开数据集上实现了对心跳间隔时间序列的预测，验证了LSTM对于时间序列中长期和短期的趋势特征具备抽象和表达能力。

但是，本文描述的模型只能被视为一个Demo，在实际应用还有以下问题要考虑：

1. 通用模型 or 专用模型：从本文的实验数据可以看出来，对于健康心跳和心律不齐两种情况下心跳间隔数组的趋势规律完全不同。在模型实际应用时，这两种情况都有可能遇到，是设计出一个包含多种规律的通用模型，还是多个不同规律的模型？如果是前者，模型结构方面需要增加复杂度，以便表征不同心跳间隔序列的关系；如果是后者，在多个规律模型之外还需要增加分类器，对于输入信号正确分类，从而选择不同的模型。
2. 离线学习 or 在线学习：从前面的实验可以看出，在一个人身上训练的模型应用于另一个人时误差会增大。那么是否可以利用在被试身上采集到的前N个心跳间隔序列对模型的部分参数做调优，使得基于大样本学习的通用模型更加适用于当前被试者本人。

3. 预测下一个心跳间隔的值 or 可能范围：这一点在文中Loss函数的选择这部分就有讨论。本文虽然采用的是预测下一个心跳间隔的值，但在实际应用中预测“可能的范围”更具有意义，没有误差范围的预测结果对实际应用难以产生指导价值。在设计能够预测“可能范围”的网络时，需要注意几个问题。首先要对预测范围做正则化，否则梯度下降法会倾向于预测范围无穷大，这样无论如何真实值都会落入范围内，但无穷大的范围预测结果是没有实际用途的；其次，一个范围预测的好或不好，需要合理设计Loss函数，这其中如果用到类似于类似Sigmoid函数的非线性变换，一定要考虑梯度丢失问题，即Sigmoid函数求导之后在 ± 3 以外的梯度快速趋向于0，不利于基于梯度下降的网络优化，极端情况下可能出现训练中梯度消失，无法优化网络